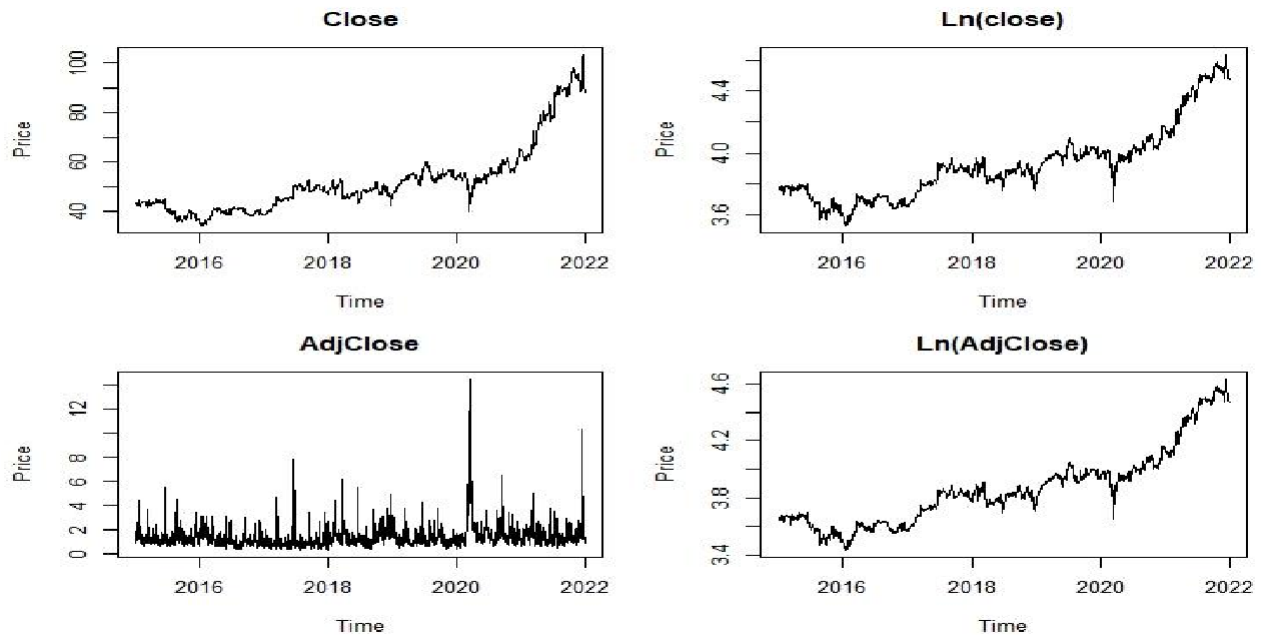


Analisi time series finanziaria: Oracle Corporation

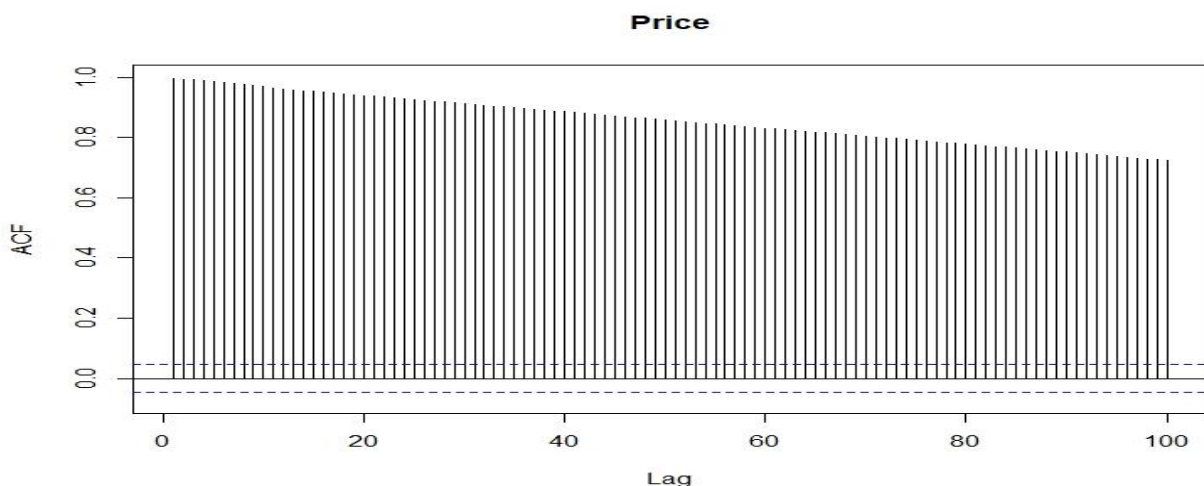
L'analisi della time series riguarda le quotazioni dell'azienda Oracle Corporation. La fonte dei dati è Yahoo Finance (<https://finance.yahoo.com/quote/ORCL?p=ORCL>). Le variabili analizzate, misurate in USD, sono: i prezzi di apertura del giorno(open), prezzo di chiusura del giorno(close), prezzo più alto del giorno(high), prezzo più basso del giorno(low), prezzi close aggiustati per i dividendi(adjusted close). Si analizzano i dati dal periodo 3 Gennaio 2015 al 31 dicembre 2021 a cadenza giornaliera (1761 osservazioni). L'obiettivo di questa analisi è di prevedere la volatilità (o varianza condizionata) nei prossimi 10 giorni.

Analisi preliminari

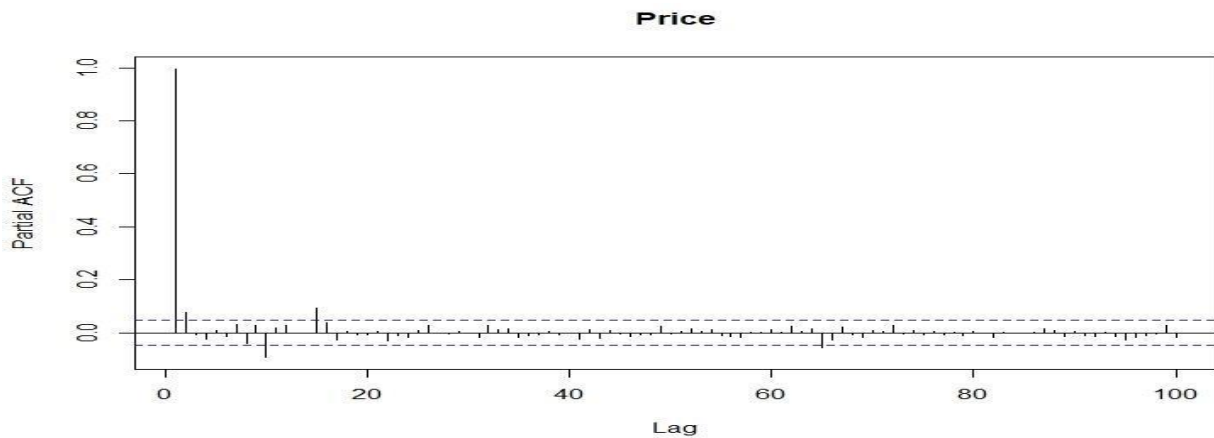


(10) Plot close e adjusted

Dal grafico (figura 10) mostra l'andamento della time series negli ultimi 6 anni. Possiamo notare che i valori sembrano crescere fino al 2020 dove hanno un picco negativo per la pandemia da COVID-19. Dalla fine del 2020 il trend sembra risalire. Il grafico non sembra mostrare traccia di stazionarietà.



(11) Acf degli ln(Adjusted)



(12) Pacf degli $\ln(\text{adjusted})$

Guardiamo i grafici (figura 11 e 12). Vediamo decadimento lineare dell'Acf e un $\phi(1)$ è prossimo a 1 che ci confermano l'assenza di stazionarietà. Si procede con il test ADF(Augmented Dickey-Fuller):

Value of test-statistic is: -2.3194 3.2684 3.6122 :

	1pct	5pct	10pct
tau3	-3.96	-3.41	-3.12
phi2	6.09	4.68	4.03
phi3	8.27	6.25	5.34

H0(1): $\gamma=0$ Stat.test -> tau3

H0(2): $\gamma=\xi=0$ Stat.test -> phi3

H0(3): $\gamma=\xi=\omega=0$ Stat.test-> phi2

Accettiamo tutte e 3 le ipotesi nulle e passiamo al terzo step.

Value of test-statistic is: 0.2578 1.3191

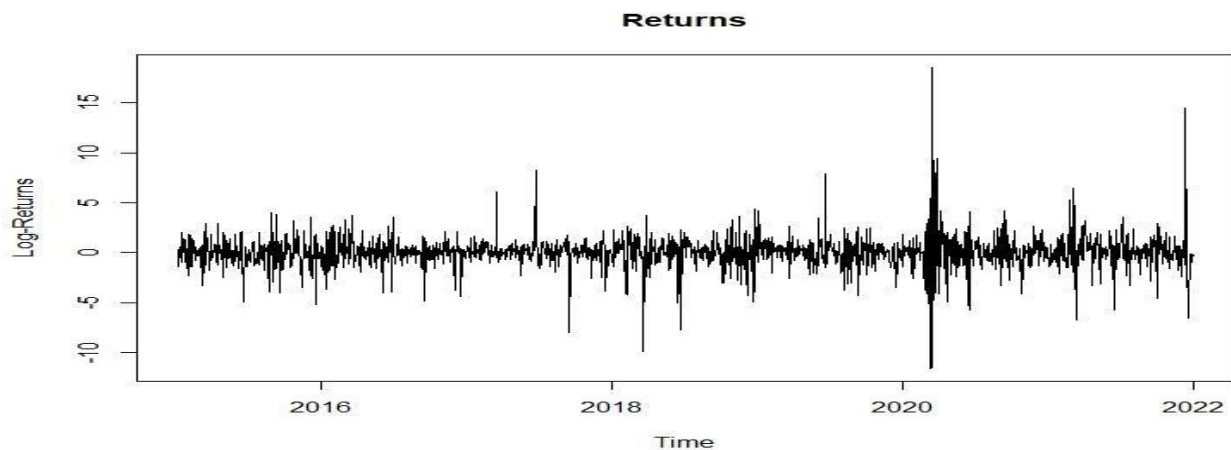
	1pct	5pct	10pct
tau2	-3.43	-2.86	-2.57
phi1	6.43	4.59	3.78

H0(5): $\gamma=0$ Stat.test -> tau2

H0(6): $\gamma=\omega=0$ Stat.test -> phi1


Accettiamo tutte e 2 le ipotesi nulle, così da confermare la presenza di unit root.

A questo punto si usa una trasformazione logaritmica per la serie dei prezzi per renderla stazionaria. Si usa la trasformazione logaritmica perché ha caratteristiche migliori rispetto alle altre trasformazioni.



(13) Log>Returns

Dal grafico (figura 13) si può notare che i log-returns si muovono intorno allo 0 come un WN, ma il WN è omoschedastico quindi la variabilità intorno alla media è sempre la stessa mentre qui no. Il grafico fa un po' da "fisarmonica" con picchi in 2018 e 2020.



(14) Acf e Pacf dei log-returns

Il grafico (figura 14) mostra Acf e Pacf dei log-returns che si comportano in maniera simile a un WN dato che i due grafici sembrano avere lo stesso andamento nelle auto-correlazioni.

Modello ARMA

Utilizziamo un modello ARMA per i log-returns. Lo modelliamo utilizzando come distribuzione dei residui la t-student perché si distribuisce meglio rispetto alla gaussiana. Assegniamo i valori di p e q migliori dal punto di vista della variazioni degli Information Criteria e prendiamo un modello ARMA(0,0):

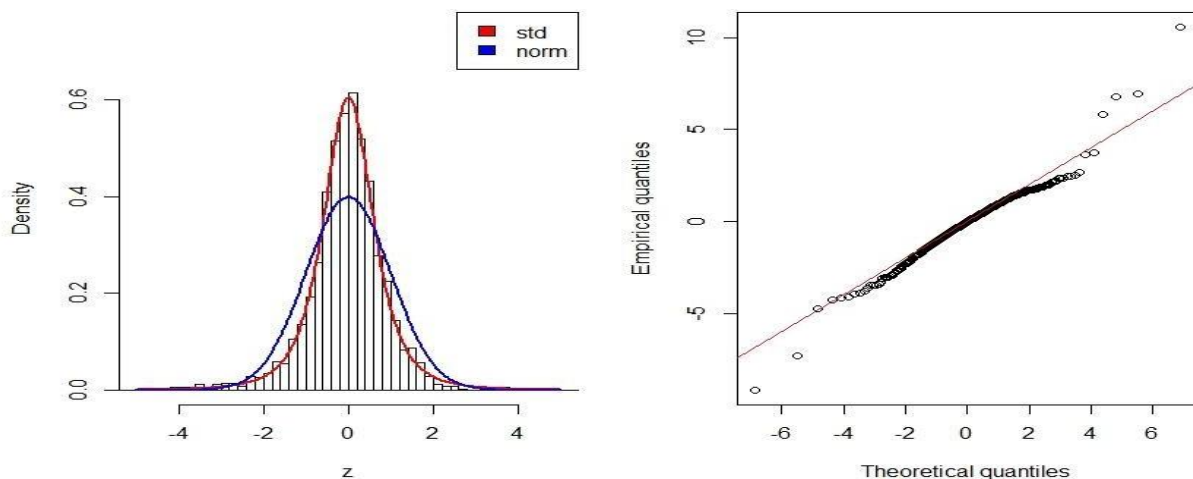
	Estimate	Std. Error	t value	Pr(> t)	Akaike	3.365064	Bayes	3.374389
mu	0.09342886	0.02308075	4.047913	5.167638e-05				
sigma	1.85297636	0.37523863	4.938128	7.887607e-07				
shape	2.53552181	0.30010546	8.448769	0.000000e+00				

Si riporta la matrice robusta dei coefficienti, robusta rispetto a un'errata specificazione della distribuzione degli errori.

Stima modelli GARCH

A questo punto stimiamo un modello GARCH e lo modelliamo come fatto in precedenza. Confrontandolo per avere risultati migliori, il modello che scegliamo è un simple-GARCH(1,1).

	Estimate	Std. Error	t value	Pr(> t)	Akaike	3.266732	Bayes	3.282273
mu	0.08852428	0.02159657	4.098998	4.149425e-05				
omega	0.27622458	0.09144830	3.020554	2.523123e-03				
alpha1	0.26406901	0.07479403	3.530616	4.145928e-04				
beta1	0.68381121	0.07201045	9.496000	0.000000e+00				
shape	3.18910496	0.27817543	11.464366	0.000000e+00				



(15) istogramma e Q-Q plot di z

Come possiamo vedere dal grafico (figura 15), la distribuzione t-student si adatta molto meglio della gaussiana.

Prima di passare alla stima del GJR-GARCH, andiamo a testare se esiste un “effetto leverage”, che spiega un possibile andamento asimmetrico della varianza condizionata.

	t-value	prob sig	Le statistiche test assumono valori non significativi e quindi concludono assenza di effetto leverage.
Sign Bias	1.5966049	0.1105337	
Negative Sign Bias	0.8342755	0.4042392	
Positive Sign Bias	0.4829762	0.6291728	
Joint Effect	4.2102696	0.2396357	

Passiamo alla stima del GJR-GARCH. Il modello migliore risulta un GJR-GARCH(1,1):

	Estimate	Std. Error	t value	Pr(> t)	Akaike	3.266871	Bayes	3.285520
mu	0.08534567	0.02201753	3.876259	0.0001060746				
omega	0.26149229	0.10072945	2.595987	0.0094319767				
alpha1	0.19477168	0.09681236	2.011847	0.0442360418				
beta1	0.69964593	0.08378907	8.350086	0.0000000000				
gamma1	0.10158426	0.10106664	1.005122	0.3148383373				
shape	3.19148065	0.27833267	11.466425	0.0000000000				

Procediamo con il test di Nyblom, che controlla la stabilità dei parametri in tutto il periodo della time series.

\$IndividualStat	\$JointStat	\$IndividualCritical			\$JointCritical		
mu	0.2650658	1.800991	10%	5%	1%	10%	5%
omega	0.6243145		0.353	0.470	0.748	1.49	1.68
alpha1	0.7375699					2.12	
beta1	0.6796808						
gamma1	0.4333401						
shape	0.8075952						


Controllando le statistiche test dei parametri risulta che tutte sono oltre il valore critico, quindi è presente stabilità. Questo grazie a un accorciamento della time series dal periodo 2011-2021 al periodo 2015-2021. Inizialmente era considerato un periodo più lungo che produceva parametri non stabili.

Passiamo adesso a stimare un altro modello GARCH, ottenuto tramite family-GARCH, che è il T-GARCH.

	Estimate	Std. Error	t value	Pr(> t)	Akaike	3.251483	Bayes	3.270132
mu	0.07476911	0.02120062	3.526742	0.0004207067				
omega	0.11663505	0.03500490	3.331964	0.0008623551				
alpha1	0.15295523	0.04349458	3.516650	0.0004370294				
beta1	0.78881917	0.04399110	17.931335	0.0000000000				
gamma1	0.09276580	0.04269946	2.172528	0.0298158275				
shape	3.29729807	0.28837903	11.433904	0.0000000000				

Si nota un miglioramento sia per gli Information Criteria sia per la significatività dei parametri.


Si riporta la curva NIC (News Impact Curve), un grafico (figura 16) che visualizza la relazione tra l'innovazione u_{t-1} e la varianza condizionata σ_t^2 . Il simple-GARCH non ha asimmetria, mentre gli altri due modelli sì anche se il GJR-GARCH si avvicina all'andamento del simple-GARCH.



(16) News Impact Curve

Diagnostica T-GARCH

Passiamo alla diagnostica di questo modello lavorando sui residui standardizzati.



(17) Acf residui standardizzati

Dai grafici sopra riportati (figura 17) risulta che i residui non sono correlati tra di loro e in quasi tutti i lag presentano auto-correlazioni all'interno delle bande di accettazione.

Proviamo anche un test bds sui residui standardizzati:

Standard Normal =

```
[ 0.5866 ] [ 1.1733 ] [ 1.7599 ] [ 2.3466 ]
[ 2 ] -1.0459 -0.7376 -0.7050 -0.9917
[ 3 ] -0.9363 -0.6644 -0.7162 -1.0874
[ 4 ] -1.0622 -0.7519 -0.8943 -1.2454
```

In questo caso si accetta l'ipotesi nulla :
varibili indipendenti e identicamente distribuite.

p-value =


```
[ 0.5866 ] [ 1.1733 ] [ 1.7599 ] [ 2.3466 ]
[ 2 ] 0.2956 0.4608 0.4808 0.3213
[ 3 ] 0.3491 0.5065 0.4738 0.2769
[ 4 ] 0.2882 0.4521 0.3712 0.2130
```

Procediamo con l'ultimo modello della famiglia GARCH, l'IGARCH:

	Estimate	Std. Error	t value	Pr(> t)	Akaike	3.266281	Bayes	3.278714
mu	0.08873035	0.02301025	3.856122	1.151999e-04				
omega	0.27977750	0.08957167	3.123505	1.787111e-03				
alpha1	0.31381024	0.06297206	4.983325	6.250092e-07				
beta1	0.68618976	NA	NA	NA				
shape	2.98210894	0.17166780	17.371393	0.000000e+00				

Modello non migliore rispetto agli altri.

Previsioni



(18) Garman-klass volatility plot

Il grafico sopra (figura 18) mostra i valori della volatilità calcolati con Garman-Klass e li confronta con i valori stimati con i modelli T-GARCH e I-GARCH. Per capire quale fra i modelli sia quello con migliore bontà di adattamento confrontiamo le misure di errore sulla volatilità e sulla varianza.

measure	model	ME	MAE	RMSE	MPE	MAPE	RMSPE	ScMAE	ScRMSE
1 Volatility	GARCH	-0.1287	0.5285	0.8095	-0.2654	0.4231	0.5995	0.8154	0.8259
2 Volatility	GJR-GARCH	-0.1265	0.5284	0.8082	-0.2658	0.4246	0.6052	0.8153	0.8246
3 Volatility	T-GARCH	-0.0824	0.4990	0.7587	-0.2278	0.3950	0.5432	0.7699	0.7741
4 Volatility	IGARCH	-0.2236	0.5722	0.8577	-0.3363	0.4699	0.6673	0.8828	0.8752
5 Variance	GARCH	-0.1009	2.1078	5.6379	-0.8902	1.1479	2.0720	0.8582	0.6899
6 Variance	GJR-GARCH	-0.0672	2.0946	5.6632	-0.8980	1.1574	2.1092	0.8529	0.6930
7 Variance	T-GARCH	0.1983	1.9380	5.8122	-0.7507	1.0234	1.7030	0.7891	0.7112
8 Variance	IGARCH	-0.5502	2.3400	5.9437	-1.1179	1.3369	2.4283	0.952	0.72735

Dai risultati possiamo vedere che il T-GARCH è migliore nella volatilità mentre nella varianza risulta migliore fatta eccezione per RMSE e SRMSE dove il GARCH presenta una misura più bassa.

Per capire se il modello stimato produce previsioni non distorte si usa il test di Mincer-Zarnowitz:

GARCH	estimate	HAC.s.e.	HAC.tstat	HAC.pvalue	(HAC) F stat: 8.88142 , df: (2 , 1759)
(Intercept)	0.3031812	0.2035538	1.489440	1.365508e-01	p-value: 0.0001452759
Fit	0.7224629	0.1410252	5.122936	3.338601e-07	
GJR-GARCH	estimate	HAC.s.e.	HAC.tstat	HAC.pvalue	(HAC) F stat: 0.8264849 , df: (2 , 1759)
(Intercept)	0.2390029	0.2175899	1.098410	2.721759e-01	p-value: 0.4377546
Fit	0.8129596	0.1600233	5.080259	4.169495e-07	
T-GARCH	estimate	HAC.s.e.	HAC.tstat	HAC.pvalue	(HAC) F stat: 4.560944 , df: (2 , 1759)
(Intercept)	0.1179080	0.1890626	0.6236452	5.329415e-01	p-value: 0.0105761
Fit	0.8672882	0.1343592	6.4549979	1.395857e-10	
I-GARCH	estimate	HAC.s.e.	HAC.tstat	HAC.pvalue	(HAC) F stat: 27.72716 , df: (2 , 1759)
(Intercept)	0.3516861	0.1963610	1.791018	7.346229e-02	p-value: 1.393689e-12
Fit	0.6515461	0.1287482	5.060623	4.615797e-07	

Tutti i beta1 sono altamente significativi, mentre i beta0 sono significativi tranne nell'IGARCH. Le statistiche test sono tutte significative tranne per GJR-GARCH. Nel modello con GJR-GARCH produrrò previsioni non distorte.

Per confrontare 2 modelli e decretare il migliore si usa il test di Diebold-Mariano:

Volatilità: (in fondo a ogni riga pvalue, e il modello migliore)

GARCH vs GJR-GARCH -> Horiz: 1 , Loss fct pow: 1 , Stat (L1-L2): 0.04955081, p-value = 0.9605 -> **GJR-GARCH**
GARCH vs GJR-GARCH -> Horiz: 1 , Loss fct pow: 2 , Stat (L1-L2): 0.2451572, p-value = 0.8064->**GJR-GARCH**
GJR-GARCH vs T-GARCH ->Horiz: 1 , Loss fct pow: 1 , Stat (L1-L2): 5.750573, p-value = 1.046e-08 ->**T-GARCH**
GJR-GARCH vs T-GARCH->Horiz: 1 , Loss fct pow: 2 , Stat (L1-L2): 3.916786, p-value = 9.316e-05 ->**T-GARCH**
GARCH vs IGARCH -> Horiz: 1 , Loss fct pow: 1 , Stat (L1-L2): -15.42402, , p-value < 2.2e-16->**GARCH**
GARCH vs IGARCH -> Horiz: 1 , Loss fct pow: 2 , Stat (L1-L2): -7.643275 , p-value = 3.458e-14->**GARCH**

Varianza: (in fondo a ogni riga pvalue, e il modello migliore)

GARCH vs GJR-GARCH -> Horiz: 1 , Loss fct pow: 1 , Stat (L1-L2): 0.6911899 , p-value = 0.4895->**GJR-GARCH**
GARCH vs GJR-GARCH -> Horiz: 1 , Loss fct pow: 2 , Stat (L1-L2): -0.1359363 , p-value = 0.8919->**GARCH**
GJR-GARCH vs T-GARCH ->Horiz: 1 , Loss fct pow: 1 , Stat (L1-L2): 3.615578, p-value = 0.0003081 ->**T-GARCH**
GJR-GARCH vs T-GARCH->Horiz: 1 , Loss fct pow: 2 , Stat (L1-L2): -0.3275093, p-value = 0.7433 ->**GJR-GARCH**
GARCH vs IGARCH -> Horiz: 1 , Loss fct pow: 1 , Stat (L1-L2): -7.361539 , p-value = 2.778e-13->**GARCH**
GARCH vs IGARCH -> Horiz: 1 , Loss fct pow: 2 , Stat (L1-L2): -1.400159 , p-value = 0.1616->**GARCH**

Nella volatilità il T-GARCH vince con il GJR-GARCH mentre nella varianza si equivalgono.

Infine, con una previsione ex-ante prevediamo H=10 nuovi valori dei rendimenti dei log(returns) in percentuale.

0-roll forecast [T0=2021-12-30]:

	Series	Sigma
T+1	0.08852	1.689
T+2	0.08852	1.727
T+3	0.08852	1.761
T+4	0.08852	1.794
T+5	0.08852	1.824
T+6	0.08852	1.852
T+7	0.08852	1.878
T+8	0.08852	1.902
T+9	0.08852	1.925
T+10	0.08852	1.947